

Proj2 皮肤病变三分类项目书

五人小组 14 天执行方案：传统图像处理、机器学习、深度学习与外部数据集适配

生物医学图像处理 Project 2

2026 年 5 月 6 日

一页版结论

本项目选择 **Proj2：皮肤病变图像三分类**。任务是根据皮肤病变图像及其 mask，预测类别为 `mel`、`nv`、`vasc` 三类，并生成符合要求的 `output.csv`。

我们不把它做成“单个深度模型分类”这么窄，而是做成一个完整系统：

基于病灶区域先验、传统图像特征与深度特征融合的皮肤病变三分类研究

最终方案建议由四部分组成：

1. **本地数据基线**：读取 `image`、`mask`、`label`，建立可复现训练与验证流程。
2. **传统图像处理 + 机器学习**：利用 `mask` 提取病灶区域，构造颜色、纹理、形状特征，并训练 SVM、Random Forest、XGBoost 等模型。
3. **深度学习**：使用预训练 MobileNetV2、ResNet18 或 EfficientNet-B0 微调三分类。
4. **外部数据适配与融合**：筛选 HAM10000 / ISIC 中的 `mel/nv/vasc` 三类，用于预训练或训练增强，再与传统特征模型做融合。

这个设计比较适合拿高分：既有课程里的图像处理，也有机器学习和深度学习；既考虑结果，也考虑可解释性和隐藏测试泛化。

1 项目背景与任务定义

1.1 任务输入

课程给定的 Proj2 数据包含：

- `image/`：皮肤病变 RGB 图像，当前本地训练集约 600 张，尺寸为 224x224。
- `mask/`：每张图对应的病灶区域 `mask`。
- `label.csv`：训练标签，格式为 `image_id, dx`。

本地标签包含三类：

标签	含义	本地样本数
<code>mel</code>	melanoma, 黑色素瘤	210
<code>nv</code>	melanocytic nevus, 黑色素细胞痣	300
<code>vasc</code>	vascular lesion, 血管性病变	90

1.2 任务输出

最终代码需要读取测试集中的 `image/` 和 `mask/`，预测每张图的类别，并输出：

```
output.csv
image_id,dx
1,nv
2,mel
3,vasc
```

其中 `dx` 只能是 `mel`、`nv`、`vasc` 三者之一。

1.3 建议评估指标

老师给的 demo 主要约束了输出格式，没有明确公布完整评分公式。考虑到类别不平衡，组内实验不能只看 `accuracy`。建议报告中至少使用：

- **Accuracy**：整体分类正确率。
- **Macro-F1**：三类 F1 的平均值，能更公平地反映少数类表现。
- **Balanced Accuracy**：三类召回率的平均值，适合不平衡数据。
- **Confusion Matrix**：分析 `mel/nv/vasc` 哪些类别容易混淆。
- **Per-class Precision / Recall / F1**：尤其关注 `mel` 和 `vasc`。

2 总体技术路线

2.1 为什么不能只做深度学习

本地数据只有 600 张，且 `vasc` 只有 90 张。如果直接训练一个深度网络，很容易出现本地验证集看起来不错、隐藏测试集掉分的情况。更稳的路线是：

- 用 `mask` 做病灶区域先验，减少背景皮肤、黑边、拍摄差异的影响。
- 用传统特征提供可解释信息，比如颜色不均匀性、边界不规则度、纹理变化。
- 用预训练深度模型提取更强的图像语义特征。
- 用融合策略提升泛化，而不是赌单个模型。

2.2 推荐系统框架

模块	作用
数据模块	读取本地 image/mask/label, 做分层划分、增强、归一化和复现控制。
传统特征模块	从病灶区域提取颜色、纹理、形状特征, 训练机器学习模型。
深度学习模块	使用预训练模型微调三分类, 并导出深度 embedding 或预测概率。
外部数据模块	处理 HAM10000/ISIC, 筛出 mel/nv/vasc, 统一标签和图像格式。
融合模块	传统特征 + 深度 embedding, 或传统模型 + 深度模型 soft voting。
评估模块	输出 accuracy、macro-F1、balanced accuracy、混淆矩阵和错误样例。
提交模块	从测试目录读取 image/mask, 生成 output.csv。

3 外部数据集适配工作

3.1 为什么这是一个独立工作

公开数据不是下载下来就能用。它需要经过标签筛选、格式统一、尺寸统一、类别平衡、质量检查和训练策略设计。这个模块完全可以作为一名组员的核心贡献。

3.2 推荐数据集

- **HAM10000**: 包含 10015 张皮肤病变图像, 类别中有 mel、nv、vasc, 与本题最匹配。
- **ISIC 2018 Task 3**: 皮肤病变诊断挑战, 可筛选出与本题一致的三类。
- **ISIC 2018 Task 1**: 病灶分割任务, 可作为 mask/病灶区域处理的参考。
- **PH2**: 较小, 适合外部验证或报告讨论, 不建议作为主训练集。

3.3 外部数据处理流程

1. 下载元数据和图片, 保留数据来源说明。
2. 筛选三类: melanoma 映射为 mel, melanocytic nevus 映射为 nv, vascular lesion 映射为 vasc。
3. 统一输出标签表: image_id, dx, source。
4. 图像统一为 RGB, resize 到 224x224。
5. 检查损坏图片、重复图片、标签缺失、异常尺寸。
6. 统计类别分布, 决定是否下采样 nv 或对 vasc 做增强。
7. 明确外部数据用途: 优先用于预训练或训练增强, 本地验证集不能混入外部验证。

3.4 建议产出文件

```
external_data/
  images/
  labels_3class.csv
  README_external_data.md
```

```
scripts/  
prepare_ham10000.py  
prepare_isic2018.py  
check_dataset.py
```

4 五人分工

建议不要按“每个人训练一个模型”来分，这样最后很难合并。更好的分法是按项目模块负责。

成员	角色	主要任务	交付物
A	项目统筹与复现负责人	搭建项目结构；确定 train/val 划分；写统一评估脚本；管理随机种子、模型保存、最终运行接口。	run.py、评估脚本、README、最终提交包。
B	传统图像处理与特征工程	处理 mask；提取病灶 ROI；构造颜色、纹理、形状特征；做特征可视化。	features.py、特征表、可视化图。
C	机器学习模型负责人	用 B 的特征训练 SVM、RF、XGBoost；调类别权重；输出特征重要性和 baseline 结果。	传统模型权重、对比表、特征重要性。
D	深度学习负责人	搭建预训练 MobileNetV2、ResNet18 或 EfficientNet-B0；做增强、训练、验证；导出 embedding 或概率。	深度模型权重、训练日志、预测概率。
E	外部数据与融合负责人	处理 HAM10000/ISIC 三类数据；统一标签；做外部数据预训练或增强；完成融合实验和报告方法部分。	外部数据处理脚本、融合模型、报告初稿。

5 14 天执行计划

时间	目标	具体任务
Day 1	跑通数据与项目结构	A 建项目目录和读取脚本；B 检查 image/mask 对应关系；全组确认提交格式和指标。
Day 2	数据分析与划分	A 做 Stratified K-Fold 或固定 train/val；B 输出样例图、mask 覆盖图；C/D 确认训练接口。
Day 3	传统特征第一版	B 提取颜色特征、基础形状特征；C 训练 Logistic/SVM/RF baseline。
Day 4	传统特征增强	B 加 LBP、GLCM、HOG、边界不规则度；C 加 XGBoost/RF 调参。

时间	目标	具体任务
Day 5	传统路线定版	C 输出传统方法对比表、混淆矩阵; B 生成特征可视化; A 整理结果格式。
Day 6	深度模型第一版	D 跑通 MobileNetV2 或 ResNet18; 使用 class weight/balanced sampler; 记录 baseline。
Day 7	深度模型调参	D 尝试 EfficientNet-B0、增强策略、冻结层策略; A 检查复现脚本。
Day 8	外部数据处理	E 完成 HAM10000/ISIC 三类筛选、标签映射、resize 和质量检查。
Day 9	外部数据接入	D/E 尝试外部数据预训练或合并训练; 保留本地验证集独立评估。
Day 10	融合实验	E 做 soft voting 或特征拼接; C/D 提供传统模型概率和深度 embedding。
Day 11	消融实验	做无 mask vs 有 mask、传统 vs 深度 vs 融合、是否使用外部数据的对比。
Day 12	最终模型冻结	A 汇总最佳方案; 固定随机种子和模型文件; 从零跑一次训练/预测流程。
Day 13	报告与展示材料	E 主写报告, A/C/D/B 补各自方法和结果; 输出混淆矩阵、错误样例、流程图。
Day 14	最终复现与提交	新建干净目录测试 <code>run.py</code> ; 生成 <code>output.csv</code> ; 整理 README 和提交压缩包。

6 实验设计

6.1 必做实验

实验	目的
传统特征 + SVM/RF/XGBoost	证明传统图像处理和机器学习可以形成可解释 baseline。
深度模型微调	验证预训练 CNN 对本任务的提升。
有 mask vs 无 mask	证明病灶区域先验是否有效。
传统 vs 深度 vs 融合	证明融合方法是否优于单一路线。
类别不平衡处理	对比 class weight、balanced sampler 或重采样的影响。

6.2 建议报告结果表

报告中可以放如下表格:

方法	Accuracy	Macro-F1	Balanced Acc	备注
传统特征 + SVM	—	—	—	baseline
传统特征 + XGBoost	—	—	—	特征重要性
MobileNetV2	—	—	—	预训练微调
EfficientNet-B0	—	—	—	轻量深度模型
传统 + 深度融合	—	—	—	最终方法

7 建议代码结构

```
proj2_team/  
  README.md  
  run.py  
  requirements.txt  
  configs/  
    default.yaml  
  models/  
    traditional_model.pkl  
    scaler.pkl  
    deep_model.pth  
    label_encoder.json  
  src/  
    dataset.py  
    features.py  
    train_ml.py  
    train_dl.py  
    fusion.py  
    evaluate.py  
    predict.py  
  scripts/  
    prepare_ham10000.py  
    prepare_isic2018.py  
    check_dataset.py  
  results/  
    metrics.csv  
    confusion_matrix.png  
    error_cases/
```

8 风险与应对

风险	可能后果	应对
深度模型过拟合	本地验证高，隐藏测试低	使用预训练轻量模型、强增强、早停、K-Fold、外部数据预训练。
类别不平衡	vasc 识别差	class weight、balanced sampler、macro-F1、错误样例分析。
外部数据分布不同	合并训练反而下降	优先做预训练；本地验证集独立保留；报告中写明筛选策略。
代码复现失败	助教无法运行	A 专门负责 <code>run.py</code> 、README、固定路径和随机种子。
融合没有提升	报告亮点不足	保留传统和深度单模型结果，融合即使小幅提升也可通过消融解释。
时间不够	模块做不完	Day 5 前必须有传统 baseline, Day 8 前必须有深度 baseline。

9 最终交付物

- 可运行代码：`run.py` 能读取测试目录并生成 `output.csv`。
- 模型文件：传统模型、`scaler`、深度模型权重、类别映射。
- 实验结果：指标表、混淆矩阵、消融实验、错误样例分析。
- 外部数据处理说明：数据来源、标签映射、筛选规则、是否用于预训练。
- 项目报告：方法背景、技术路线、实验设计、结果分析、局限性。
- README：环境依赖、运行命令、输入输出格式。

最后建议

这个项目的关键不是把某个模型调到看起来最高，而是把一套可信的实验链条做完整。前 5 天先把传统图像处理和机器学习路线做稳，保证项目有底；第 6 到 10 天再集中做深度学习、外部数据和融合；最后 4 天不要再大改方向，主要做复现、报告和消融。

如果执行顺利，最终项目会有一个很清楚的逻辑：**mask 提供病灶先验，传统特征提供解释性，深度模型提供表达能力，外部数据提升泛化，融合模型作为最终预测器。**